


Clasificación

Modelo de REGRESIÓN LOGÍSTICA

Clasificación – Modelo de REGRESIÓN LOGÍSTICA

Cómo logramos encontrar una línea (hiperplano) que permita discriminar entre dos categorías?

Cada registro de un dataset que esté por encima del hiperplano ($w^T x > 0$) se clasifica como un ejemplo positivo, mientras que cada ejemplo por debajo del hiperplano ($w^T x < 0$) se clasifica como un ejemplo negativo.



Llevamos esto a un dataset concreto

Clasificación – Modelo de REGRESIÓN LOGÍSTICA

Contexto


Este dataset es originario del Instituto Nacional de Diabetes y Enfermedades Digestivas y Renales. El objetivo del conjunto de datos es predecir de manera diagnóstica si un paciente tiene o no diabetes, en función de ciertas medidas de diagnóstico incluidas en el conjunto de datos. Se impusieron varias restricciones a la selección de estas instancias de una base de datos más grande. En particular, todos los pacientes aquí son mujeres de al menos 21 años de herencia indígena pima.

Atributos

Pregnancies : Número de veces que la persona ha estado embarazada.
Glucose : Concentración de glucosa en plasma a las 2 horas en una prueba de tolerancia oral a la glucosa.
BloodPressure : Presión arterial diastólica (mm Hg).
SkinThickness : Espesor del pliegue cutáneo del tríceps (mm).
Insulin : Insulina sérica a las 2 horas (mu U/ml).
BMI : Índice de masa corporal (peso en kg dividido por la altura al cuadrado).
DiabetesPedigreeFunction: Función de pedigrí de diabetes (indica predisposición genética).
Age : Edad (años).
Outcome : Target (0 or 1)

Objetivo

Construir un modelo de aprendizaje automático para predecir con precisión si los pacientes en el conjunto de datos tienen diabetes o no.



<https://www.kaggle.com/code/rishpande/pima-indians-diabetes-beginner/notebook>

Clasificación – Modelo de REGRESIÓN LOGÍSTICA

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
0	6	148	72	35	0	33.6	0.627	50	1
1	1	85	66	29	0	26.6	0.351	31	0
2	8	183	64	0	0	23.3	0.672	32	1
3	1	89	66	23	94	28.1	0.167	21	0
4	0	137	40	35	168	43.1	2.288	33	1
5	5	116	74	0	0	25.6	0.201	30	0
6	3	78	50	32	88	31.0	0.248	26	1
7	10	115	0	0	0	35.3	0.134	29	0
8	2	197	70	45	543	30.5	0.158	53	1
9	8	125	96	0	0	0.0	0.232	54	1

Clasificación – Modelo de REGRESIÓN LOGÍSTICA

En este problema queremos predecir la probabilidad de que una persona **tenga diabetes** en función de sus características clínicas, como nivel de glucosa, presión arterial, índice de masa corporal, edad, entre otras. Formalmente, buscamos estimar la probabilidad condicional $P(Y = 1 | X)$, donde Y es la variable objetivo (tener diabetes = 1, no tener diabetes = 0) y X representa el conjunto de variables de entrada. La **regresión logística** no entrega directamente una predicción de “sí” o “no”, sino un valor entre 0 y 1 que indica la probabilidad de pertenecer a la clase positiva. A partir de ese valor, aplicamos un umbral (típicamente 0.5): si la probabilidad estimada es mayor al umbral, clasificamos al paciente como “con diabetes”; en caso contrario, como “sin diabetes”.

$$p = P(y = 1 | \mathbf{x})$$

Clasificación – Modelo de REGRESIÓN LOGÍSTICA

La regresión logística plantea que no trabajamos directamente con la probabilidad $p=P(Y=1|X)$, sino con el logit, es decir, el logaritmo de la razón de probabilidades:

$$\text{logit}(p) = \log \frac{p}{1-p}$$

The log-odds (logit) function

Esta razón compara la probabilidad de que el paciente tenga diabetes (p) contra la probabilidad de que no la tenga ($1-p$). La hipótesis del modelo es que este logit se puede expresar como una combinación lineal de las variables de entrada, por ejemplo:

$$\text{logit}(p) = \beta_0 + \beta_1(\text{Glucosa}) + \beta_2(\text{BMI}) + \beta_3(\text{Edad}) + \dots$$

Donde:

$p=P(Y=1|X)$: es la probabilidad de que la persona tenga diabetes.

$p/1-p$: es la razón de probabilidades.

Los coeficientes β : indican cuánto aporta cada variable (glucosa, BMI, edad, etc.) al riesgo de tener diabetes.

$$\log \left(\frac{p}{1-p} \right) = \beta_0 + \beta_1 \cdot (\text{Glucosa}) + \beta_2 \cdot (\text{BMI}) + \beta_3 \cdot (\text{Edad}) + \dots$$

Clasificación – Modelo de REGRESIÓN LOGÍSTICA

Los puntos para los que $p = 0,5$ (es decir, el logaritmo de probabilidades es igual a 0) definen el hiperplano de separación entre las dos clases, cuya ecuación es:

$$\log \frac{p}{1-p} = w_0 + w_1x_1 + \dots + w_mx_m = \mathbf{w}^T \mathbf{x}$$

$$\mathbf{w}^T \mathbf{x} = 0$$

The equation of the separating hyperplane

El modelo tiene la palabra "logística" en su nombre, ya que utiliza la función logística (sigmoide) para convertir una combinación lineal de las características de entrada en probabilidades.

Ahora (umbral 0,7):


- Clasifica como clase 1 si:

$$w^T x \geq \log \left(\frac{0.7}{0.3} \right)$$

REGRESIÓN LOGÍSTICA INTERPRETACIÓN

$$\log \frac{p}{1-p} = \beta_0 + \beta_1 x$$


$$p = \frac{1}{1 + e^{-\frac{(\beta_0 + \beta_1 x)}{\beta_2}}}$$



Clasificación – Modelo de REGRESIÓN LOGÍSTICA

Cada ejemplo por encima del hiperplano ($w^T x > 0$) se clasifica como un ejemplo positivo, mientras que cada ejemplo por debajo del hiperplano ($w^T x < 0$) se clasifica como un ejemplo negativo.

Esto convierte a la regresión logística en un clasificador lineal, ya que asume que el límite entre las clases es una superficie lineal.



Función de costo de Regresión logística

https://www.youtube.com/watch?v=26d_WAo1ZoM

Taller Regresión logística

Exploración de datos

Preparación de datos

Entrenamiento del modelo

Evaluación del modelo Regresión logística


Clasificación

Balanceo Clase Target

Balanceo

Es una desproporción entre las clase de la variable target.

El algoritmo tendrá una preferencia de predicción para la clase mayoritaria, mientras que para la clase minoritaria los clasificará erróneamente, porque no hay tantos datos, para que pueda aprender patrones que ayuden en su predicción.



Estrategias de Balanceo

Modificar el Dataset (submuestreo)

- Reduce las muestras de la clase mayoritaria para equilibrar el dataset, pero puede eliminar datos valiosos y afectar el rendimiento del modelo.

Modificar el Dataset (sobremuestreo)

- Aumenta las muestras de la clase minoritaria, generalmente duplicándolas con reemplazo; puede generar duplicados que limiten la diversidad y favorezcan el sobreajuste.

Ajuste de Parámetros del Modelo

- Permite equilibrar clases desbalanceadas penalizando a la clase mayoritaria durante el entrenamiento.
- Ejemplo: usar `class_weight="balanced"` en árboles de decisión o regresión logística

Muestras Artificiales (SMOTE)

- Genera nuevas instancias sintéticas de la clase minoritaria siguiendo su tendencia, pero puede alterar su distribución natural.
- SMOTE crea ejemplos combinando vecinos cercanos y también puede reducir la clase mayoritaria para equilibrar el dataset.

Taller Regresión logística

Exploración de datos

Preparación de datos

Balancear variable target

Entrenamiento del modelo

Evaluación del modelo Regresión logística

Consultas

